

# MATD49-Estatística não paramétrica

## 6 – Testes de Wald-Wolfowitz

Kim Samejima

IME-UFBA

# Teste de Wald-Wolfowitz para tendência I

- Considere uma amostra de tamanho  $N$  de uma v.a.  $X$ ,  $\{x_1, \dots, x_N\}$  tal que as unidades amostrais possam ser categorizadas em dois grupos diferentes:  $A$  e  $B$ ;
- Se  $X$  é contínua, empates nos valores de  $X$ , em tese, não ocorrem, no sentido de que  $P(X_{n+k} = x_n) = 0$  para todo  $n$  e  $k \neq 0$ ;
- Desta forma, teríamos uma ordenação natural  $x_{(1)}, \dots, x_{(N)}$ . Ainda teríamos também uma ordenação natural dentro de cada grupo  $A$  e  $B$ :  $x_{A,(1)}, \dots, x_{A,(n_A)}$  e  $x_{B,(1)}, \dots, x_{B,(n_B)}$ ;
- Logo, se não há diferença entre as distribuições de  $X|A$  e  $X|B$ , a ordem dos elementos dos grupos  $A$  e  $B$  na amostra deve ser aleatória;
- Por exemplo, se  $n_A = 5$  e  $n_B = 6$ , poderíamos ter
  - **AABABABBBAB**, ou seja, o primeiro e segundo elementos da amostra são do grupo  $A$ , o terceiro é de  $B$  etc.;
  - Por outro lado também poderíamos ter **BBBBBBAAAAA**;

## Teste de Wald-Wolfowitz para tendência II

- No primeiro exemplo tínhamos uma mistura aleatória dos grupos A e B, sugerindo naquela amostra que não há diferença entre as distribuições de  $X$  nos grupos A e B, ao passo que no segundo temos que a  $X$  no grupo B assume valores menores do que no grupo A.
- Sob a hipótese de que a distribuição de  $X$  não muda nos grupos A e B:

$$H_0 : F_{X|A}(x) = F_{X|B}(x),$$

desejamos avaliar se a ordem que estas observações aparecem possui tendência ou é aleatória. A hipótese alternativa será:

$$H_a : F_{X|A}(x) \neq F_{X|B}(x).$$

- Defina a variável  $R$  como o número total de grupos repetidos (*RUNS*) que temos na categorização da amostra em grupos A e B. Por exemplo:
  - Em AABABABBBAB, teríamos  $R = 8$ ;
  - Em BBBBBBAAAAA, teríamos  $R = 2$ ;
- Rejeitamos  $H_0$  para valores pequenos de  $R$ .

## Teste de Wald-Wolfowitz para tendência III

- Sob  $H_0$ , a distribuição de  $R$  é dada por:

$$f_R(r) = \begin{cases} 2 \frac{\binom{n_A - 1}{r/2 - 1} \binom{n_B - 1}{r/2 - 1}}{\binom{n_A + n_B}{n_A}} & , \text{ se } r \text{ é par} \\ \frac{\binom{n_A - 1}{(r-1)/2} \binom{n_B - 1}{(r-3)/2} + \binom{n_A - 1}{(r-3)/2} \binom{n_B - 1}{(r-1)/2}}{\binom{n_A + n_B}{n_A}} & , \text{ se } r \text{ é ímpar} \end{cases} \quad (1)$$

### Demonstração.

Em linhas gerais, é dada considerando o princípio fundamental da contagem. Veja [Gibbons and Chakraborti, 2011], Teorema 3.2.2. Valores tabelados para esta distribuição podem ser encontrados na mesma referência. □

## Teste de Wald-Wolfowitz para tendência IV

- É possível mostrar que, para valores de  $n_A$  e  $n_B$  grandes ( $>20$ ), podemos aproximar a distribuição de  $R$  por uma distribuição Normal:

$$R \stackrel{a}{\sim} N(\mu, \sigma^2),$$

em que:

$$\mu = \frac{2n_A n_B}{N} + 1,$$

$$\sigma = \sqrt{\frac{2n_A n_B (2n_A n_B - N)}{N^2 (N - 1)}}.$$

Demonstração.

TCL.



## Exemplo [Gibbons and Chakraborti, 2011] I

Verificar que uma distribuição de Qui-quadrado pode ser aproximada por uma distribuição Normal para um número de g.l. grande, ao nível 5%.

- Vamos então avaliar a aderência de seus quantis utilizando os quantis da normal;
- Duas ditribuições de tamanho 8 foram geradas aleatoriamente para as variáveis  $\chi^2_{18}$  e normal padrão;
- O resultado foi:

Normal	-1.91	-1.22	-0.96	-0.72	0.14	0.82	1.45	1.86
$\chi^2_{18}$	4.90	7.25	8.04	14.10	18.30	21.21	23.10	28.12

- Antes de ordenar as observações, é preciso padronizar os dados da distr. de qui-quadrado para ter média zero e variância 1, assim como a normal. Vamos então, subtrair a média e dividir pelo seu desvio-padrão:

Normal	-1.91	-1.22	-0.96	-0.72	0.14	0.82	1.45	1.86
$(\chi^2_{18} - \nu)/\sqrt{2\nu}$	-2.18	-1.79	-1.66	-0.65	-0.05	0.54	0.85	1.69

- Os dados ordenados ficam:

$-2.18, -1.91, -1.79, -1.66, -1.22, -0.96, -0.72, -0.65, -0.05, 0.14, 0.54, 0.82, 0.85, 1.45, 1.69, 1.86$

# Exemplo [Gibbons and Chakraborti, 2011] II

- Vamos agora calcular o número de *runs*:

(i)	1	2	3	4	5	6	7	8
$X_{(i)}$	-2.18	-1.91	-1.79	-1.66	-1.22	-0.96	-0.72	-0.65
R	Q	N	Q	Q	N	N	N	Q

(i)	9	10	11	12	13	14	15	16
$X_{(i)}$	-0.05	0.14	0.54	0.82	0.85	1.45	1.69	1.86
R	Q	N	Q	N	Q	N	Q	N

- Logo o número de *runs* neste exemplo é  $R = 12$ .
- Consultando os valores tabelados da Tabela D de [Gibbons and Chakraborti, 2011], temos que o p-valor para  $n_A = n_B = 8$  e  $R = 12$  é  $p = 0.9$ . Logo, não rejeitamos  $H_0$  ao nível 5%.

# Aspecto Computacional I


## No R:

```
### DescTools::RunsTest: ###
RunsTest(x, y = NULL, alternative = c("two.sided", "less", "greater"),
         exact = NULL, correct = TRUE, na.rm = FALSE, ...)
x: Vetor com as categorias dos grupos ou vetor numerico.
y: Vetor numerico para ser comparado com x.
   Se x eh numerico e y=NULL, o R testa x contra sua mediana.
alternative: Hipotese alternativa.
exact: Aprox. pela Normal? (TRUE/FALSE).
na.rm: Remover NAs? (TRUE/FALSE).

### randtests::runs.test ###
runs.test(x, alternative, threshold, pvalue, plot).
x: Vetor numerico.
alternative: Hipotese alternativa
             ("two.sided", "left.sided", "right.sided").
threshold: Ponto de corte para construir os grupos de x.
pvalue: Aproximado ou exato? ("normal", "exact").
plot: plotar o grafico? (TRUE/FALSE).
```



# Referências I

-  Gibbons, J. D. and Chakraborti, S. (2011).  
*Nonparametric statistical inference*.  
Crc Press, Cop.